

## Blatt 1

F. Freter, E. Kirchberger, S. Symhoven & J. Wustl


### Aufgabe 2a: Statistik

1. Dichte, Erwartungswert, Varianz und Kovarianz

- a) Die Dichte der gleichverteilten 1D-Zufallsvariable  $x$  im Intervall  $[a, b] \subset \mathbb{R}$  ist definiert als:

$$p(x) = \begin{cases} \frac{1}{b-a} & \text{für } a \leq x \leq b \\ 0 & \text{sonst} \end{cases}$$

und kann wie folgt skizziert werden:



Die Dichte auf dem Intervall  $[a, b]$  hat den Wert  $\frac{1}{b-a}$ .

- b) Erwartungswert:

$$\begin{aligned} E[X] &= \int_{-\infty}^{\infty} x p(x) dx \\ &= \int_a^b x \cdot \frac{1}{b-a} dx \\ &= \frac{1}{b-a} \cdot \left[ \frac{x^2}{2} \right]_a^b \\ &= \frac{b^2 - a^2}{2(b-a)} \\ &= \frac{a+b}{2} \end{aligned}$$

- c) Varianz

$$\begin{aligned}
\text{Var}(X) &= E[(x - \mu_x)^2] \\
&= \int_a^b (x - \mu_x)^2 p(x) dx \\
&= \int_a^b \left(x - \frac{a+b}{2}\right)^2 \cdot \frac{1}{b-a} dx \\
&= \left[ \frac{1}{3} \left(x - \frac{a+b}{2}\right)^3 \cdot \frac{1}{b-a} \right]_a^b \\
&= \frac{1}{3(b-a)} \left( \left(b - \frac{a+b}{2}\right)^3 - \left(a - \frac{a+b}{2}\right)^3 \right) \\
&= \frac{1}{3(b-a)} \left( \left(\frac{b-a}{2}\right)^3 + \left(\frac{b-a}{2}\right)^3 \right) \\
&= \frac{1}{3(b-a)} 2 \left(\frac{b-a}{2}\right)^3 \\
&= \frac{2 \left(\frac{b-a}{2}\right)^3}{3(b-a)} \\
&= \frac{2 \left(\frac{b-a}{2}\right)^3}{3(b-a)} \\
&= \frac{1}{12} \cdot (b-a)^2
\end{aligned}$$

## 2. Sample Mean und Kovarianzmatrix

a)

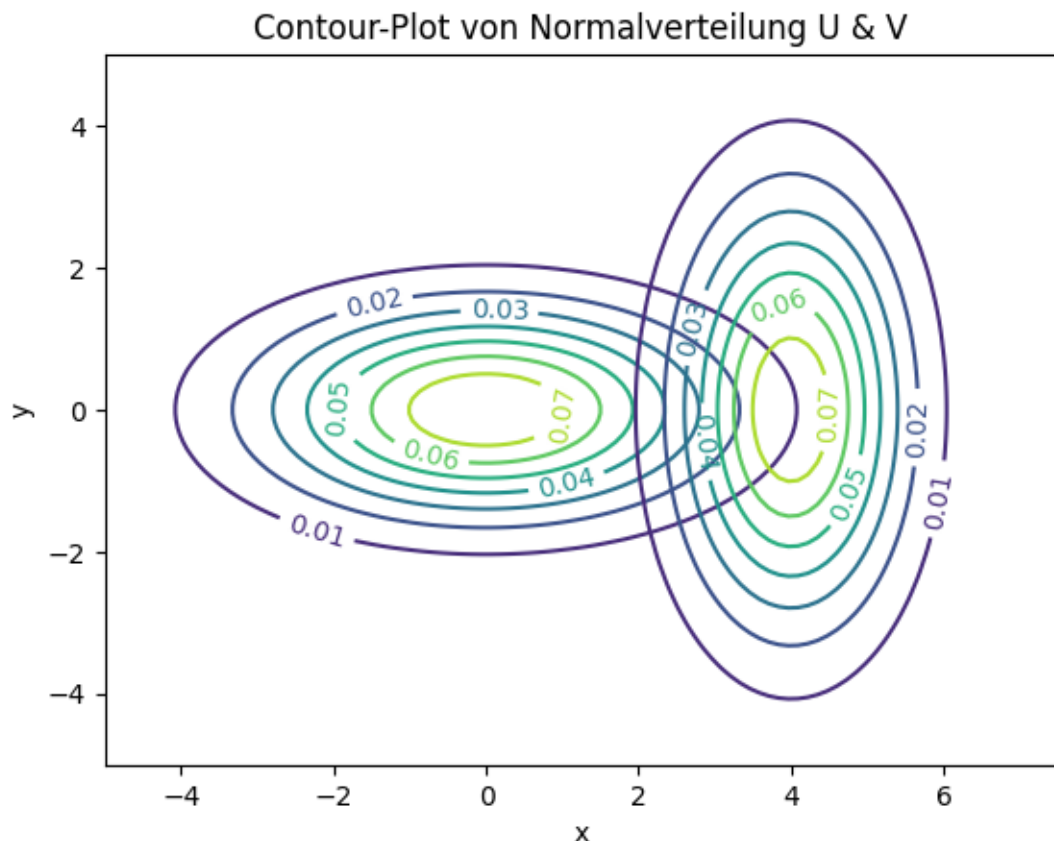
$$\begin{aligned}
\mu_X &= \frac{1}{n} \sum_i X_i \\
&= \frac{1}{4} \sum_{i=1}^4 X_i \\
&= \frac{1}{4} * \left[ \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} -1 \\ -1 \end{pmatrix} + \begin{pmatrix} -5 \\ 1 \end{pmatrix} + \begin{pmatrix} 1 \\ 2 \end{pmatrix} \right] \\
&= \frac{1}{4} \begin{pmatrix} -4 \\ 4 \end{pmatrix} \\
&= \begin{pmatrix} -1 \\ 1 \end{pmatrix}
\end{aligned}$$

b)

$$\begin{aligned}
\sum_{\mathbf{x}\mathbf{x}} &= \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \mu_{\mathbf{x}})(\mathbf{x}_i - \mu_{\mathbf{x}})^T \\
&= \frac{1}{4} \left[ \begin{pmatrix} 2 \\ 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \end{pmatrix} + \begin{pmatrix} 0 \\ 2 \end{pmatrix} \begin{pmatrix} 0 & 2 \end{pmatrix} + \begin{pmatrix} -4 \\ 0 \end{pmatrix} \begin{pmatrix} -4 & 0 \end{pmatrix} + \begin{pmatrix} 2 \\ 1 \end{pmatrix} \begin{pmatrix} 2 & 1 \end{pmatrix} \right] \\
&= \frac{1}{4} \left[ \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} + \begin{pmatrix} 0 & 0 \\ 0 & 4 \end{pmatrix} + \begin{pmatrix} 16 & 0 \\ 0 & 0 \end{pmatrix} + \begin{pmatrix} 4 & 2 \\ 2 & 1 \end{pmatrix} \right] \\
&= \frac{1}{4} \begin{pmatrix} 24 & 4 \\ 4 & 6 \end{pmatrix} \\
&= \begin{pmatrix} 6 & 1 \\ 1 & 1.5 \end{pmatrix}
\end{aligned}$$

### 3. Multivariate Normalverteilung

- a) Die beiden Verteilungen der Zufallsvariablen  $\mathbf{u}$  und  $\mathbf{v}$  liegen wie folgt im x/y-Koordinatensystem. Die Verteilung der Zufallsvariable  $\mathbf{u}$  entspricht der horizontalen Ellipse links. Diese hat den Mittelpunkt im Ursprung, eine Varianz von 4 in x-Richtung und eine Varianz von 2 in y-Richtung. Die Verteilung der Zufallsvariable  $\mathbf{v}$  entspricht der vertikalen Ellipse rechts. Diese hat den Mittelpunkt um 4 in x-Richtung verschoben, eine Varianz von 2 in x-Richtung und eine Varianz von 4 in y-Richtung:



- b) Die Trennfunktion muss eine Funktion sein, die die Grenze zwischen den beiden Verteilungen darstellt.

Bei einer Bayes-Entscheidungsregel lautet die Trennfunktion:


$$T(x) = \log \left( \frac{p(x|C_1)}{p(x|C_2)} \right) + \log \left( \frac{p(C_2)}{p(C_1)} \right) \quad (1)$$

mit  $p(x|C_i)$  als der Wahrscheinlichkeit, dass  $x$  in der Klasse  $C_i$  liegt, und  $p(C_i)$  als der A-priori-Wahrscheinlichkeit der Klasse  $C_i$ .

Da in diesem Fall die A-priori-Wahrscheinlichkeiten der beiden Verteilungen gleich sind, vereinfacht sich die Gleichung zu:

$$T(x) = \log \left( \frac{p(x|U)}{p(x|V)} \right) \quad (2)$$

Die Trennfunktion sieht dann wie folgt aus:



#### 4. Entropie einer diskreten Verteilung

a)

$$I_1 = -\ln(P(1)) = -\ln(0.2) \approx 1.6094$$

b)

$$I_2 = -\ln(P(2)) = -\ln(0.8) \approx 0.2231$$

c)

$$\begin{aligned} H(X) &= - \sum P(x) \cdot \ln(P(x)) \\ &= -[P(1) \cdot \ln(P(1)) + P(2) \cdot \ln(P(2))] \\ &= -[0,2 \cdot \ln(0,2) + 0,8 \cdot \ln(0,8)] \\ &\approx 0,5004 \end{aligned}$$

d)

$$\begin{aligned} H(X) &= - \sum P(x) \cdot \ln(P(x)) \\ &= -[P(1) \cdot \ln(P(1)) + P(2) \cdot \ln(P(2))] \\ &= -[0,1 \cdot \ln(0,1) + 0,9 \cdot \ln(0,9)] \\ &\approx 0,4689 \end{aligned}$$

Die Entropie ist etwas niedriger als zuvor, was darauf hindeutet, dass die Verteilung jetzt etwas vorhersehbarer ist. Das macht Sinn, da die Wahrscheinlichkeit für Ereignis  $P_2$  gestiegen und für  $P_1$  gefallen ist. Dass  $P_2$  eintritt, ist nun also sicherer als vorher und die Entropie somit geringer, da das Ergebnis vorhersehbarer wird.

## Aufgabe 2b: Statistik

### 1 Imports

```
[5]: import numpy as np
import os
import matplotlib.pyplot as plt
import matplotlib.cm as cm
from scipy.stats import multivariate_normal
```

### 2 Berechnen des Mittelwertsvektors und der Kovarianzmatrix

```
[6]: x1 = np.array([[1], [2]])
x2 = np.array([[-1], [-1]])
x3 = np.array([[-5], [1]])
x4 = np.array([[1], [2]])

# Stichprobenmatrix erstellen
X = np.hstack((x1, x2, x3, x4))

X_mean = np.mean(X, axis=1, keepdims=True)

print(f'Mittelwertsvektor:\n {X_mean}')
```

Mittelwertsvektor:

```
[[ -1.]
 [ 1.]]
```

```
[7]: C = (1 / X.shape[1]) * np.dot((X - X_mean), (X - X_mean).T)

print(f'Auto Kovarianzmatrix:\n {C}')
```

Auto Kovarianzmatrix:

```
[[6.  1.]
 [1.  1.5]]
```

### 3 Subplot Funktion für 3D-, Contour- & 2D-Sample-Plot

```
[8]: def generate_plts(mean, cov, sample_size):
    # Gitter erstellen und anhand der Mean/Cov automatisch scalen
    cov_max = max(cov[0][0], cov[1][1])
    mean_max = max(mean[0], mean[1])
    x_min = y_min = mean_max - 3 * np.sqrt(cov_max)
    x_max = y_max = mean_max + 3 * np.sqrt(cov_max)

    x, y = np.meshgrid(np.linspace(x_min, x_max, 100), np.linspace(y_min,
↪ y_max, 100))
    pos = np.dstack((x, y))
```

```

# Normalverteilungswerte berechnen
rv = multivariate_normal(mean, cov)
z = rv.pdf(pos)

# Zufällige Samples generieren
samples = rv.rvs(sample_size)

fig = plt.figure(figsize=(24,7))

# 3D Plot
ax1 = fig.add_subplot(1, 3, 1, projection='3d')
ax1.set_title('3D-Distribution')
ax1.plot_surface(x, y, z, cmap='viridis', linewidth=0)
ax1.set_xlabel('X')
ax1.set_ylabel('Y')
ax1.set_zlabel('Z')

# Contour Plot
ax2 = fig.add_subplot(1, 3, 2)
ax2.set_title('Contour-Plot')
ax2.set_xlabel('X')
ax2.set_ylabel('Y')
cp = ax2.contour(x, y, z)
ax2.clabel(cp, inline=True, fontsize=10)

# 2D-Distribution of random sample
ax3 = fig.add_subplot(1, 3, 3)
ax3.set_title('2D-Distribution')
ax3.set_xlabel('X')
ax3.set_ylabel('Y')
ax3.scatter(samples[:, 0], samples[:, 1], alpha=0.5)

plt.axis('equal')

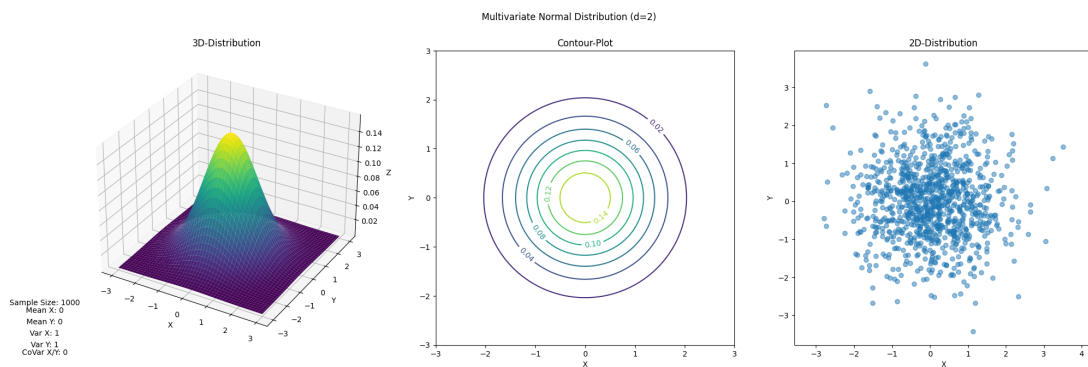
fig.suptitle('Multivariate Normal Distribution (d=2)')

fig.text(0.1, 0.22, f'Sample Size: {sample_size}',
↪horizontalalignment='center', verticalalignment='center')
fig.text(0.1, 0.2, f'Mean X: {mean[0]}', horizontalalignment='center',
↪verticalalignment='center')
fig.text(0.1, 0.17, f'Mean Y: {mean[1]}', horizontalalignment='center',
↪verticalalignment='center')
fig.text(0.1, 0.14, f'Var X: {cov[0][0]}', horizontalalignment='center',
↪verticalalignment='center')
fig.text(0.1, 0.11, f'Var Y: {cov[1][1]}', horizontalalignment='center',
↪verticalalignment='center')

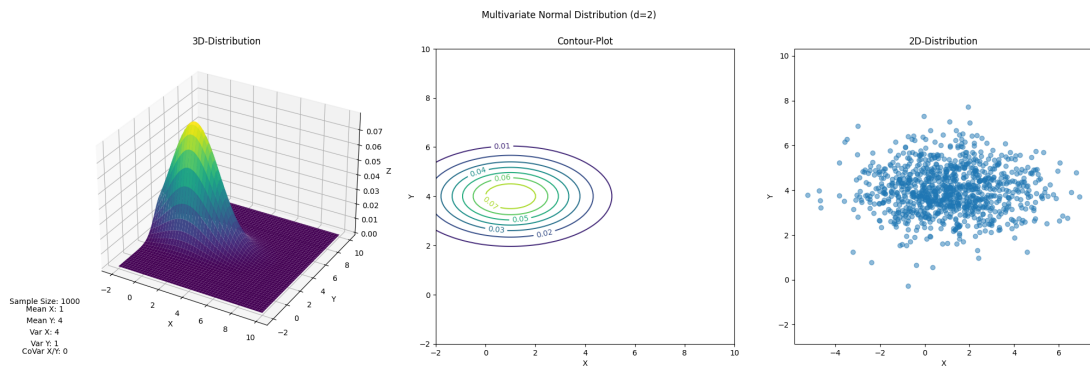


```


```
fig.text(0.1, 0.09, f'CoVar X/Y: {cov[0][1]}',  
horizontalalignment='center', verticalalignment='center')  
plt.show()
```

```
[11]: sample_size = 1000  
  
# Mittelwert, Kovarianzmatrix und Sample Size definieren  
mean = [0, 0]  
cov = [[1, 0], [0, 1]]  
generate_plts(mean, cov, sample_size)  
  
mean = [0, 0]  
cov = [[1, 0], [0, 5]]  
generate_plts(mean, cov, sample_size)  
  
mean = [3, 3]  
cov = [[2, 0], [0, 2]]  
generate_plts(mean, cov, sample_size)  
  
mean = [1, 4]  
cov = [[4, 0], [0, 1]]  
generate_plts(mean, cov, sample_size)  
  
mean = [0, 1]  
cov = [[3, 1], [1, 2]]  
generate_plts(mean, cov, sample_size)
```









## 4 Lage von U & V

```
[105]: # Parameter für die erste Normalverteilung
mean_u = [0, 0]
cov_u = [[4, 0], [0, 1]]

# Parameter für die zweite Normalverteilung
mean_v = [4, 0]
cov_v = [[1, 0], [0, 4]]

# Gitter erstellen
x, y = np.meshgrid(np.linspace(-5, 7.5, 100), np.linspace(-5, 5, 100))
pos = np.dstack((x, y))


# PDFs der Normalverteilungen berechnen
rv_u = multivariate_normal(mean_u, cov_u)
z_u = rv_u.pdf(pos)

rv_v = multivariate_normal(mean_v, cov_v)
z_v = rv_v.pdf(pos)

# Contour-Plots erstellen
fig, ax = plt.subplots()
cp_u = ax.contour(x, y, z_u)
ax.clabel(cp_u, inline=True, fontsize=10)
cp_v = ax.contour(x, y, z_v)
ax.clabel(cp_v, inline=True, fontsize=10)

# Titel und Achsenbeschriftungen hinzufügen
ax.set_title('Contour-Plot von Normalverteilung U & V')
ax.set_xlabel('x')
ax.set_ylabel('y')
```

```
# Schaubild anzeigen
plt.show()
```



## 5 Trennfunktion für U & V

```
[106]: # Trennfunktion berechnen
z_trenn = np.log(rv_u.pdf(pos) / rv_v.pdf(pos))

# Contour-Plots erstellen
fig, ax = plt.subplots()
cp_u = ax.contour(x, y, z_u)
ax.clabel(cp_u, inline=True, fontsize=10)
cp_v = ax.contour(x, y, z_v)
ax.clabel(cp_v, inline=True, fontsize=10)
cp_trenn = ax.contour(x, y, z_trenn, levels=0, linewidths=1)

# Titel und Achsenbeschriftungen hinzufügen
```

```

ax.set_title('Contour-Plot von Normalverteilung U & V mit Trennfunktion')
ax.set_xlabel('x')
ax.set_ylabel('y')

# Schaubild anzeigen
plt.show()

```

