CART-KLASSIFIKATOR

PATTERN MATCHING & MACHINE LEARNING

F. Freter, E. Kirchberger, S. Symhoven & J. Wustl

HM*

SOMMERSEMESTER 2023

20. JUNI 2022

Hochschule München University of Applied Sciences Fakultät für Informatik und Mathematik

INHALT

- 1 Training und Aufbau des Baumes
- 2 Bewertungsmaße für einen Split
- 3 Overfitting und Pruning
- 4 Vor- und Nachteile
- 5 Verbesserungsmöglichkeiten & Ausblick

1 | 15

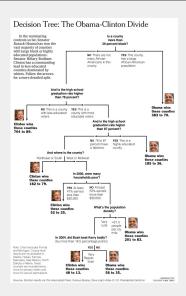


CART: CLASSIFICATION AND REGRESSION TREES

CART-Algorithmen: Ist ein Binary-Decisson Tree Verfahren, welches für Klassifizierung (kategorisch) und Regression (kontinuierlich) verwendet werden kann.

Classification Trees

Im Folgenden fokussieren wir uns auf die Classification Trees.



AUFBAU EINES CLASSIFICATION TREES

- Root Node: Startpunkt, enthält alle Daten und startet die Unterteilung (basierend auf Merkmal mit Informationsgewinn).
- Decision Node: Teilt Daten weiter auf, basierend auf Merkmalen.
- Leaf Node: Endpunkte repräsentieren finale Vorhersagen (basierend auf Merkmalen des gegebenen Datenpunkts). Keine weiteren sinnvollen Teilungen möglich.

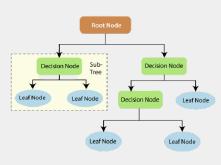


Abbildung: Decision Tree [1]

AUFBAU EINES CLASSIFICATION TREES

- Root Node: Startpunkt, enthält alle Daten und startet die Unterteilung (basierend auf Merkmal mit Informationsgewinn).
- Decision Node: Teilt Daten weiter auf, basierend auf Merkmalen.
- Leaf Node: Endpunkte repräsentieren finale Vorhersagen (basierend auf Merkmalen des gegebenen Datenpunkts). Keine weiteren sinnvollen Teilungen möglich.

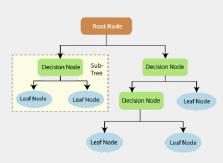


Abbildung: Decision Tree [1]

Ziel

Optimale Vorhersagen auf Basis von Eingangsmerkmalen.

ALLGEMEINE STRATEGIE

Allgemeine Strategie: Eingangsdaten werden in P disjunkte Regionen R_1, \ldots, R_P aufgeteilt. wobei jede Region R_p eine Entscheidungsklasse Y_p repräsentiert. **Binary Splitting**, Beispiel: $x_i <= a$

Trainings Methodology:

- Aufteilung des Ausgangsraums R in R₁ und R₂
- Suche nach der besten Aufteilung für R₁ und R₂
- Wiederhole für alle erzeugten Regionen

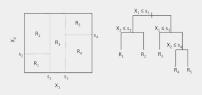


Abbildung: Rekursive Teilung [2]

VORGEHEN BEI KLASSIFIKATION

Um ein neues Sample X zu klassifizieren:

- Test der Attribute von X um die zutreffende Region zu finden für die Klassenverteilung $y_r = (y_{c_1}, \dots, y_{c_k})$.
- Die Wahrscheinlichkeit das ein Punkt $X \in \mathcal{R}$ zu einer Gruppe gehört, ist definiert durch

$$p(y = c|\mathcal{R}) = \frac{y_c, \mathcal{R}}{\sum_{c_i \in C} y_{c_i}, \mathcal{R}}.$$

■ Ein neues Sample bekommt die Zuteilung welche am häufigsten in der jeweiligen Region ist.

$$\hat{y} = rg \max_{c} p(y = c|x) = rg \max_{c} p(y = c|\mathcal{R}) = rg \max_{c} y_{c,\mathcal{R}}$$

DER BESTE SPLIT

Problem: Wie finde ich den besten Split?

Direkte Optimierung ist schwer umsetzbar, da die iterative Überprüfung aller Bäume bei komplexeren Daten schnell explodiert.

Mögliche Lösung:

Greedy Heuristic: Bei jedem Schritt wird die aktuell optimale Entscheidung getroffen

GREEDY HEURISTIC

Hierbei wird eine Node aufgeteilt, wenn sie den Misclassification Error (ME) i_E an Node t verbessert.

$$i_E(t) = 1 - \max_c p(y = c|t)$$

Die Verbesserung bei Durchführung eines Splitts s von t zu t_R und t_L für $i(t) = i_E(t)$ ist wie folgt definiert:

$$\Delta i(s,t) = i(t) - p_L \cdot i(t_L) - p_R \cdot i(t_R)$$

PROBLEME MIT MISCLASSIFICATION ERROR

Problem 1: Kein Splitt durchgeführt bei $i_E(t) = \frac{40}{200}$, obwohl verbesserte Klassifikation möglich, durch Kombination von Tests.

$$x_1 \le 5 : p_L \cdot i_E(t_L) - p_R \cdot i_E(t_R) = \frac{40}{200}$$

 $x_2 \le 3 : p_L \cdot i_E(t_L) - p_R \cdot i_E(t_R) = \frac{40}{200}$

Problem 2: Schlechte Sensitivität zur Veränderung der Klassenwahrscheinlichkeiten. Verteilung vor Split: (400, 400)

Split
$$a: \{(100, 300), (300, 100)\} \rightarrow i_E(t, a) = 0.25$$

Split $b: \{(200, 400), (200, 0)\} \rightarrow i_E(t, b) = 0.25$

Lösung: Ein Kriterium welches als Maß für die Reinheit der Klassenverteilung an Node *t* verwendet werden kann.



BEWERTUNGSMASSE: GINI-INDEX, INFORMATIONSGE-WINN & MISSCLASSIFICATION ERROR

■ Gini-Index

- ► Maß der Unreinheit einer Gruppe
- \blacktriangleright $i_G(t) = 1 \sum_{i=1}^k \pi_i^2$, wobei π_i die Wkt. der Klasse i ist.
- ► Ziel: Minimierung des gewichteten Gini-Indexes.

■ Informationsgewinn: Entropy

- ► Reduktion der Entropie durch den Split
- ► $IG = H(parent) \sum_{i=1}^{m} \frac{n_i}{n} H(child_i)$, wobei H die Entropie ist.
- ► **Ziel**: Maximierung des Informationsgewinns.

■ Missclassification Error

- ► Der Misclassification Error (ME) ist ein Maß für die Fehlklassifizierung.
- $ightharpoonup i_E(t) = 1 \max_c p(y = c|t)$
- ► ME kann als Bewertungsmaß für die Baumkonstruktion verwendet werden.

GINI-INDEX

Misst, wie oft eine zufällig ausgewählte Instanz falsch klassifiziert würde, wenn sie gemäß der Klassenverteilung zufällig klassifiziert wird.

- Die Gini-Unreinheit ist ein Wert zwischen o (vollständig rein, alle Elemente gehören zur gleichen Klasse) und 1 (maximal unrein, gleichmäßige Verteilung der Klassen).
- Die Gini-Unreinheit für einen Knoten t mit K Klassen kann wie folgt berechnet werden:

$$i_G(t) = \sum_{c_i \in C} \underbrace{\pi_{c_i}}_{ \begin{subarray}{c} Wahrscheinlichkeit, \\ ein Element auszuwählen \end{subarray}} \cdot \underbrace{\left(1 - \pi_{c_i}\right)}_{ \begin{subarray}{c} Wahrscheinlichkeit, \\ dass es falsch \\ klassifiziert wird \end{subarray}}$$

OVERFITTING UND PRUNING

OVERFITTING IN DECISION TREES

Daten werden rekursiv aufgeteilt und lassen den DT dadurch wachsen. Wann sollte man das Wachstum stoppen um overfitting zu vermeiden?

Mögliche Stop- (oder Pruning-) Kriterien:

- Verteilung im Ast ist rein, d.h. i(t) = o
- Maximale Tiefe erreicht
- Anzahl der Proben in jedem Ast unterhalb eines bestimmten Schwellenwerts t_n
- Nutzen der Aufteilung ist unterhalb eines bestimmten Schwellenwerts $\Delta i(s,t) < t\Delta$
- Genauigkeit auf dem Validierungsset
- **Ziel**: Erstellung eines Modells, das gut auf neue, ungesehene Daten verallgemeinert und somit Overfitting vermeidet.

PRUNING METHODS

Alternativ kann der Baum zunächst vollständig wachsen und anschließend beschnitten werden (**Post-Pruning**).

Verschiede Pruning-Methoden:

- Reduced Error Pruning
- Minimum Description Length Pruning
- Cost-Complexity Pruning

COST-COMPLEXITY PRUNING

- **Ziel**: Verhindern von Overfitting durch Entfernen von Zweigen, die wenig zur Vorhersageleistung beitragen
- **Kostenkomplexitätspruning**: Gleichgewicht zwischen Baumgröße und Trainingsfehler
- **■** Kostenkomplexitätskriterium:

$$C_{\alpha}(T) = C(T) + \alpha |T|$$
, mit

- ightharpoonup C(T) ist der Misclassification Error des Baumes T.
- ightharpoonup |T| ist die Anzahl der terminalen Knoten des Baumes T.
- ightharpoonup lpha ist ein Komplexitätsparameter, der die Präferenz zwischen Baumgröße und Trainingsfehler steuert.
- lacktriangle Durch Variieren von lpha kann eine Sequenz optimaler Bäume ermittelt werden.
- Kreuzvalidierung kann verwendet werden, um den optimalen Wert von α zu bestimmen.

VOR- UND NACHTEILE

Vorteile:

- leicht zu trainieren
- leicht zu interpretieren
- einfach zu visualisieren
- können mit verschiedenen Prädiktoren umgehen \rightarrow keine Dummies erforderlich

Nachteile:

- nicht die besten Lerner
- reagieren empfindlich auf sich ändernde Trainingsdaten
- werden von den oben genannten Splits dominiert → erster Split beeinflusst stark die Form des gesamten Baums

VERBESSERUNGSMÖGLICHKEITEN

AUSBLICK

- **Stacking**: Ensemble-Lern-Technik. Mehrere CART-Modelle kombiniert werden. Ausgaben der einzelnen Modelle werden als Eingabe für ein Meta-Modell verwendet.
- Bayesian Model Averaging: Modellselektion. Mehrere Modelle auf der Grundlage von Bayes'schen Wahrscheinlichkeiten kombiniert werden.
- **Bagging**: Ensemble-Lern-Technik. Mehrere CART-Modelle werden auf unterschiedlichen Stichproben der Daten trainiert.
- Random Forests: Ensemble-Lern-Modell. Besteht aus vielen unkorrelierten Entscheidungsbäumen, die auf zufälligen Untergruppen der Daten trainiert werden.
- **Boosting**: Ensemble-Lern-Technik. Sequentielle Anordnung von schwachen CART-Modellen, wobei jeder Baum versucht, die Fehler des vorherigen Baums zu korrigieren.

REFERENCES I



BAHZAD CHARBUTY AND ADNAN MOHSIN ABDULAZEEZ.

CLASSIFICATION BASED ON DECISION TREE ALGORITHM FOR MACHINE
LEARNING.

Journal of Applied Science and Technology Trends, 2021.



TREVOR HASTIE, ROBERT TIBSHIRANI, AND JEROME FRIEDMAN. **THE ELEMENTS OF STATISTICAL LEARNING, 2009.**

FRAGEN, KRITIK ODER ANREGUNGEN?