

CART-KLASSIFIKATOR

PATTERN MATCHING & MACHINE LEARNING

F. FRETER, E. KIRCHBERGER,
S. SYMHOVEN & J. WUSTL

SOMMERSEMESTER 2023

20. JUNI 2022



Hochschule München
University of Applied Sciences
Fakultät für Informatik und Mathematik

- 1 Training und Aufbau des Baumes
- 2 Bewertungsmaße für einen Split
- 3 Overfitting und Pruning
- 4 Vor- und Nachteile
- 5 Verbesserungsmöglichkeiten & Ausblick

TRAINING UND AUFBAU DES BAUMES

CART: CLASSIFICATION AND REGRESSION TREES

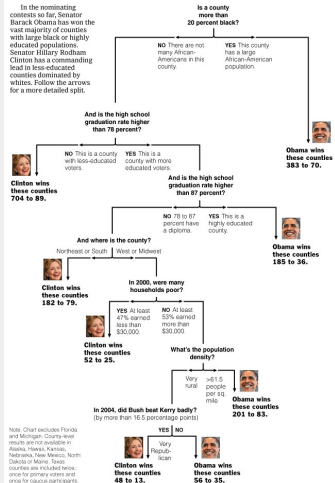
CART-Algorithmen: Ist ein Binary-Decission Tree verfahren, welches für **Klassifizierung** (kategorisch) und **Regression** (kontinuierlich) verwendet werden kann.

Classification Trees

Im Folgenden fokussieren wir uns auf die **Classification Trees**.

Decision Tree: The Obama-Clinton Divide

In the nominating contests so far, Senator Barack Obama has won the vast majority of counties with large black or highly educated populations. Senator Hillary Rodham Clinton has a commanding lead in less-educated counties dominated by whites. Follow the arrows for a more detailed split.



Sources: Election results via The Associated Press; Census Bureau; Dave Leip's Atlas of U.S. Presidential Elections

AMERICAN OVERSIGHT

Abbildung: Decision Tree [2]

AUFBAU EINES CLASSIFICATION TREES

- **Root Node:** Startpunkt, enthält alle Daten und startet die Unterteilung (basierend auf Merkmal mit Informationsgewinn).
- **Decision Node:** Teilt Daten weiter auf, basierend auf Merkmalen.
- **Leaf Node:** Endpunkte repräsentieren finale Vorhersagen (basierend auf Merkmalen des gegebenen Datenpunkts). Keine weiteren sinnvollen Teilungen möglich.

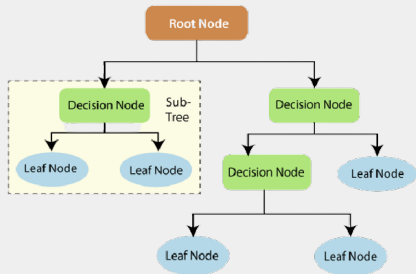


Abbildung: Decision Tree [1]

AUFBAU EINES CLASSIFICATION TREES

- **Root Node:** Startpunkt, enthält alle Daten und startet die Unterteilung (basierend auf Merkmal mit Informationsgewinn).
- **Decision Node:** Teilt Daten weiter auf, basierend auf Merkmalen.
- **Leaf Node:** Endpunkte repräsentieren finale Vorhersagen (basierend auf Merkmalen des gegebenen Datenpunkts). Keine weiteren sinnvollen Teilungen möglich.

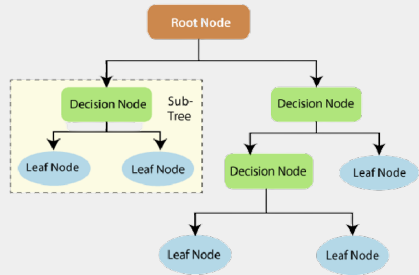


Abbildung: Decision Tree [1]

Ziel

Optimale Vorhersagen auf Basis von Eingangsmerkmalen.

Allgemeine Strategie: Eingangsdaten werden in P disjunkte Regionen R_1, \dots, R_P aufgeteilt. wobei jede Region R_p eine Entscheidungsklasse Y_p repräsentiert. **Binary Splitting**, example.: $x_i \leq a$

■ Traings Methodology:

- ▶ Aufteilung des Ausgangsraums R in R_1 und R_2
- ▶ Suche nach der besten Aufteilung für R_1 und R_2
- ▶ Wiederhole für alle erzeugten Regionen




Abbildung: Rekursive Teilung [2]

Um ein neues Sample X zu klassifizieren:

- Test der Attribute von X um die zutreffende Region zu finden für die Klassenverteilung $y_r = (y_{c_1}, \dots, y_{c_k})$
- Die Wahrscheinlichkeit das ein Punkt $X \in \mathcal{R}$ zu einer Gruppe gehört, ist definiert durch

$$p(y = c|\mathcal{R}) = \frac{y_{c, \mathcal{R}}}{\sum_{c_i \in \mathcal{C}} y_{c_i, \mathcal{R}}}$$

- Ein neues Sample bekommt die Zuteilung welche am häufigsten in der jeweiligen Region ist.

$$\hat{y} = \arg \max_c p(y = c|x) = \arg \max_c p(y = c|\mathcal{R}) = \arg \max_c y_{c, \mathcal{R}}$$

Problem: Wie finde ich den besten Split?

Direkte Optimierung schwer umsetzbar, da die Komplexität als NP-complete definiert ist. Mögliche Lösung:

- **Greedy Heuristic:** Bei jedem schritt wird die aktuell optimale Entscheidung getroffen

Hierbei wird eine Node aufgeteilt, wenn sie den Misclassification Error (ME) i_E an Node t verbessert.

$$i_E(t) = 1 - \max_c p(y = c|t)$$

Die Verbesserung bei Durchführung eines Splitts s von t zu t_R und t_L für $i(t) = i_E(t)$ ist wie folgt definiert:

$$\Delta i(s, t) = i(t) - p_L \cdot i(t_L) - p_R \cdot i(t_R)$$

PROBLEME MIT MISCLASSIFICATION ERROR

Problem 1: Kein Splitt durchgeführt $i_E(t) = \frac{40}{200}$, obwohl perfekte Klassifikation möglich durch Kombination von beiden Tests.

$$x_1 \leq 5 : p_L \cdot i_E(t_L) - p_R \cdot i_E(t_R) = \frac{40}{200}$$

$$x_2 \leq 3 : p_L \cdot i_E(t_L) - p_R \cdot i_E(t_R) = \frac{40}{200}$$

Problem 2: Keine Sensitivität zur Veränderung der Klassenwahrscheinlichkeiten. Before split: (400, 400)

Split $a : \{(100, 300), (300, 100)\} \rightarrow i_E(t, a) = 0.25$

Split $b : \{(200, 400), (200, 0)\} \rightarrow i_E(t, b) = 0.25$

Lösung: Ein Kriterium welches als Maß für die Reinheit der Klassenverteilung an Node t verwendet werden kann.

BEWERTUNGSMASSE FÜR EINEN SPLIT

BEWERTUNGSMASSE: GINI-INDEX, INFORMATIONSGEWINN & MISSCLASSIFICATION ERROR

■ Gini-Index

- ▶ Maß der Unreinheit einer Gruppe
- ▶ $Gini = 1 - \sum_{i=1}^k p_i^2$, wobei p_i die Wkt. der Klasse i ist.
- ▶ **Ziel:** Minimierung des gewichteten Gini-Indexes.

■ Informationsgewinn: Entropy

- ▶ Reduktion der Entropie durch den Split
- ▶ $IG = H(parent) - \sum_{j=1}^m \frac{n_j}{n} H(child_j)$, wobei H die Entropie ist.
- ▶ **Ziel:** Maximierung des Informationsgewinns.

■ Missclassification Error

- ▶ Der Misclassification Error (ME) ist ein Maß für die Fehlklassifizierung.
- ▶ $i_E(t) = 1 - \max_c p(y = c|t)$
- ▶ ME kann als Bewertungsmaß für die Baumkonstruktion verwendet werden.

Misst, wie oft eine zufällig ausgewählte Instanz falsch klassifiziert würde, wenn sie gemäß der Klassenverteilung zufällig klassifiziert würde.

- Die Gini-Unreinheit ist ein Wert zwischen 0 (vollständig rein, alle Elemente gehören zur gleichen Klasse) und 1 (maximal unrein, gleichmäßige Verteilung der Klassen).
- Die Gini-Unreinheit für einen Knoten t mit K Klassen kann wie folgt berechnet werden:

$$i_G(t) = \sum_{c_i \in C} \underbrace{\pi_{c_i}}_{\text{Wahrscheinlichkeit, ein Element auszuwählen}} \cdot \underbrace{(1 - \pi_{c_i})}_{\text{Wahrscheinlichkeit, dass es falsch klassifiziert wird}}$$

OVERFITTING UND PRUNING

OVERFITTING IN DECISION TREES

Wir teilen die Daten rekursiv auf und lassen den DT dadurch wachsen. Wann sollte man das Wachstum stoppen um overfitting zu vermeiden?

Mögliche Stop- (oder Pruning-) Kriterien:

- Verteilung im Ast ist rein, d.h. $i(t) = 0$
- Maximale Tiefe erreicht
- Anzahl der Proben in jedem Ast unterhalb eines bestimmten Schwellenwerts t_n
- Nutzen der Aufteilung ist unterhalb eines bestimmten Schwellenwerts $\Delta i(s, t) < t\Delta$
- Genauigkeit auf dem Validierungsset
- **Ziel:** Erstellung eines Modells, das gut auf neue, ungesehene Daten verallgemeinert und somit Overfitting vermeidet.

Alternativ kann der Baum zunächst vollständig wachsen und anschließend beschnitten werden (**Post-Pruning**).

Verschiede Pruning-Methoden:

- Reduced Error Pruning
- Minimum Description Length Pruning
- Cost-Complexity Pruning
- Im folgenden gehen wir auf das Cost-Complexity Pruning genauer ein.

COST-COMPLEXITY PRUNING

- **Ziel:** Verhindern von Overfitting durch Entfernen von Zweigen, die wenig zur Vorhersageleistung beitragen
- **Kostenkomplexitätspruning:** Gleichgewicht zwischen Baumgröße und Trainingsfehler
- **Kostenkomplexitätskriterium:**

$$C_{\alpha}(T) = C(T) + \alpha|T|, \text{ mit}$$

- ▶ $C(T)$ ist der Misclassification Error des Baumes T .
 - ▶ $|T|$ ist die Anzahl der terminalen Knoten des Baumes T .
 - ▶ α ist ein Komplexitätsparameter, der die Präferenz zwischen Baumgröße und Trainingsfehler steuert.
- Durch Variieren von α kann eine Sequenz optimaler Bäume ermittelt werden.
 - Kreuzvalidierung kann verwendet werden, um den optimalen Wert von α zu bestimmen.

VOR- UND NACHTEILE

Vorteile:

- leicht zu trainieren
- leicht zu interpretieren
- einfach zu visualisieren
- können mit verschiedenen Prädiktoren umgehen
→ keine Dummies erforderlich

Nachteile:

- nicht die besten Lerner
- reagieren empfindlich auf sich ändernde Trainingsdaten
- werden von den oben genannten Splits dominiert
→ erster Split beeinflusst stark die Form des gesamten Baums

VERBESSERUNGSMÖGLICHKEITEN & AUSBLICK

- **Stacking:** Ensemble-Lern-Technik. Mehrere CART-Modelle kombiniert werden. Ausgaben der einzelnen Modelle werden als Eingabe für ein Meta-Modell verwendet.
- **Bayesian Model Averaging:** Modellselektion. Mehrere Modelle auf der Grundlage von Bayes'schen Wahrscheinlichkeiten kombiniert werden.
- **Bagging:** Ensemble-Lern-Technik. Mehrere CART-Modelle werden auf unterschiedlichen Stichproben der Daten trainiert.
- **Random Forests:** Ensemble-Lern-Modell. Besteht aus vielen unkorrelierten Entscheidungsbäumen, die auf zufälligen Untergruppen der Daten trainiert werden.
- **Boosting:** Ensemble-Lern-Technik. Sequentielle Anordnung von schwachen CART-Modellen, wobei jeder Baum versucht, die Fehler des vorherigen Baums zu korrigieren.

REFERENCES I



BAHZAD CHARBUTY AND ADNAN MOHSIN ABDULAZEEZ.

CLASSIFICATION BASED ON DECISION TREE ALGORITHM FOR MACHINE LEARNING.

Journal of Applied Science and Technology Trends, 2021.



TREVOR HASTIE, ROBERT TIBSHIRANI, AND JEROME FRIEDMAN.

THE ELEMENTS OF STATISTICAL LEARNING, 2009.

FRAGEN, KRITIK ODER ANREGUNGEN?